

Reconocimiento de gestos manuales mediante sensores EMG para la gestión de comandos en interfaces robóticas.

Guillermo Lozano González

Universidad CEU San Pablo, Madrid, España, guillermo.lozanogonzalez@usp.ceu.es

Resumen

En este trabajo se presenta un sistema monocanal de adquisición y procesamiento de señales electromiográficas (EMG) de bajo coste orientado al reconocimiento de gestos manuales para aplicaciones de interacción humano-máquina y generación de señales de control. La señal fue adquirida mediante un sensor de superficie conectado a un Arduino Uno con una frecuencia de muestreo de 1000 Hz. Se desarrolló una cadena de procesamiento digital y clasificación basada en Random Forest para el reconocimiento automático de gestos musculares. El sistema fue evaluado sobre tres gestos manuales (puño cerrado, pulgar hacia arriba y palma abierta) y el estado de reposo.

1. Introducción

Las interfaces basadas en señales electromiográficas (EMG) han cobrado gran relevancia en aplicaciones como prótesis mioeléctricas, robótica y sistemas de interacción humano-máquina, debido a su capacidad para capturar la actividad muscular de forma no invasiva.

Trabajos como los de Benalcázar y Sami han abordado la clasificación de gestos mediante señales EMG, destacando el uso de configuraciones multicanal que permiten capturar información espacial de la actividad muscular y mejorar el rendimiento de los modelos. En este contexto, bases de datos públicas como NinaPro, que proporcionan señales EMG multicanal de alta calidad, han sido ampliamente utilizadas como estándar para el entrenamiento y evaluación de algoritmos de clasificación.

Sin embargo, los sistemas multicanal presentan un mayor coste computacional y de adquisición, lo que dificulta su utilización en aplicaciones portátiles o de bajo coste. Por ello, en este trabajo se propone un sistema monocanal de adquisición y procesamiento EMG orientado al reconocimiento de gestos manuales.

El presente trabajo se centra exclusivamente en el reconocimiento de gestos manuales mediante señales electromiográficas (EMG) para su posible utilización en sistemas de control gestual aplicados a interfaces robóticas. El alcance del estudio comprende la adquisición de señales EMG, su procesamiento digital, la segmentación de activaciones musculares, la extracción de características y la clasificación automática de gestos mediante técnicas de aprendizaje automático.

Además, el sistema contempla una arquitectura básica de interpretación y ejecución de comandos orientada a aplicaciones de control gestual. En primer lugar, el

clasificador Random Forest procesa las características extraídas de la señal EMG y genera una etiqueta numérica asociada al gesto detectado. Dicha etiqueta se almacena temporalmente en un buffer de memoria compartida que actúa como interfaz entre la etapa de clasificación y la capa de actuación. Posteriormente, un segundo proceso independiente monitoriza de forma continua dicho buffer y traduce la etiqueta recibida en una instrucción de control específica para el actuador o sistema robótico correspondiente. Finalmente, una vez ejecutada la acción física asociada al gesto, el contenido del buffer se elimina automáticamente con el objetivo de evitar ejecuciones repetidas del mismo comando en ciclos posteriores. Esta arquitectura desacoplada permite separar el procesamiento electromiográfico de la capa de actuación física, facilitando la escalabilidad y futura integración sobre hardware robótico real, aunque dicha implementación física definitiva queda fuera del alcance del presente trabajo.

2. Metodología

La señal EMG fue adquirida mediante un sensor de superficie (SEN0240, DFRobot) conectado a un Arduino Uno, con una frecuencia de muestreo de 1000 Hz. Los electrodos se colocaron sobre el músculo flexor del antebrazo, aproximadamente a 4–5 cm del epicóndilo medial. Se empleó gel conductor para reducir la impedancia piel-electrodo y mejorar la calidad de la señal, aumentando así la relación señal-ruido (SNR).

El preprocesado de la señal consistió en la aplicación de un filtro Notch a 50 Hz para eliminar la interferencia de la red eléctrica, seguido de un filtro paso banda entre 20 y 450 Hz, correspondiente al rango fisiológico característico de las señales EMG de superficie. Posteriormente, se realizó la rectificación completa de la señal y un suavizado mediante una media móvil de 50 ms, obteniendo así la envolvente de la señal.

Se empleó una ventana de 50 ms al proporcionar un compromiso adecuado entre suavizado y conservación de la dinámica temporal de la señal.

La validación del proceso de filtrado se muestra en la Figura 1, Figura 2 y Figura 3, donde se observa la eliminación de la componente de 50 Hz y la limitación del espectro al rango fisiológico.




Figura 1. PSD raw




Figura 2. PSD tras el filtro Notch




Figura 3. PSD tras el filtro paso banda (20-450 Hz)

El análisis de la densidad espectral de potencia (PSD) evidencia una clara reducción del componente en 50 Hz tras el filtrado, lo que valida la eficacia del preprocesado aplicado.

Posteriormente, la aplicación del filtro paso banda (20–450 Hz) elimina las componentes de baja frecuencia asociadas a artefactos de movimiento, así como el ruido de alta frecuencia, concentrando la energía de la señal en el rango fisiológico característico del EMG de superficie.

La detección de activaciones se realizó mediante un umbral adaptativo definido sobre la envolvente. Se observó que valores bajos de α (factor de sensibilidad) incrementaban la sensibilidad del sistema, generando detecciones espurias debidas al ruido de fondo, mientras que valores elevados provocaban la pérdida de activaciones reales. El valor final seleccionado (0.3) permitió un compromiso adecuado entre sensibilidad y robustez, permitiendo detectar de forma consistente las regiones de actividad muscular sin introducir fragmentaciones excesivas ni falsas activaciones aisladas. Además, este valor produjo máscaras binarias temporalmente más estables y coherentes con la morfología visual de la señal EMG procesada, facilitando posteriormente la segmentación y extracción fiable de características.

Con el objetivo de mejorar la robustez frente al ruido y evitar detecciones aisladas de corta duración, se aplicó un filtro de consistencia temporal mediante una media móvil de 200 ms sobre la máscara binaria obtenida. Este procedimiento permitió suavizar transiciones bruscas y

eliminar activaciones espurias generadas por pequeñas fluctuaciones residuales de la señal o por cruces puntuales del umbral. La ventana temporal de 200 ms fue seleccionada de forma experimental al proporcionar un equilibrio adecuado entre estabilidad y resolución temporal, ventanas más cortas mantenían falsas detecciones de muy breve duración, mientras que ventanas excesivamente largas tendían a fusionar activaciones cercanas y a degradar la precisión en la delimitación temporal de los gestos musculares.

En la Figura 4 se muestran la señal rectificada, la envolvente suavizada y el umbral adaptativo aplicado.




Figura 4. Segmentación aplicando umbral adaptativo

Finalmente, la máscara regularizada se obtiene mediante una segunda binarización, donde $\theta = 0.3$ es el umbral de persistencia temporal empleado, el cual fue elegido tras analizar su efecto sobre la continuidad de los segmentos detectados. Valores inferiores daban lugar a activaciones fragmentadas y sensibles al ruido, mientras que valores superiores eliminaban segmentos válidos. El valor seleccionado permitió mantener únicamente activaciones con suficiente persistencia temporal, mejorando la calidad de los segmentos utilizados en etapas posteriores.

Este procedimiento permite eliminar activaciones espurias de corta duración y evitar la fragmentación de los segmentos. Adicionalmente, se aplicó un criterio de duración mínima de 0.5 s para descartar segmentos no fisiológicos, así como un proceso de fusión de segmentos cercanos utilizando un umbral temporal de 0.8 s. Finalmente, se realizó un recorte de 200 ms en los extremos de cada segmento (trimming) con el fin de eliminar las zonas de transición entre reposo y activación para evitar su influencia en la extracción de características.

A partir de los segmentos obtenidos, se extrajeron características temporales mediante ventanas deslizantes de 200 ms con un solapamiento del 50% que permitió aumentar la resolución temporal de las características extraídas manteniendo una redundancia moderada entre ventanas consecutivas. Las características utilizadas fueron el valor cuadrático medio (RMS), el valor absoluto medio (MAV), el número de cruces por cero (ZC), la varianza (VAR) y la longitud de onda (WL).

La relación señal-ruido (SNR) se estimó a partir de la relación entre la potencia de la señal en ventanas de activación y de reposo, obteniendo una SNR que entre los tres gestos ronda alrededor de los 10 dB. La potencia se calculó mediante el valor RMS.

Para el proceso de benchmarking con la base de datos NinaPro, la señal fue sometida a la misma cadena de procesamiento digital. Las repeticiones fueron alineadas

respecto al pico de activación y recortadas mediante una ventana temporal de 5 segundos centrada en dicho pico, con el objetivo de garantizar la comparabilidad entre señales. Posteriormente, se realizó un promediado de las repeticiones (folding), obteniendo una señal media representativa del gesto.

Finalmente, tanto la señal experimental como la señal de referencia fueron normalizadas en el rango [0,1], permitiendo una comparación directa de su morfología.

La similitud entre ambas señales se evaluó mediante el coeficiente de correlación de Pearson y el error cuadrático medio (RMSE), mientras que el rendimiento del sistema de clasificación se evaluó mediante un modelo Random Forest utilizando validación cruzada basada en GroupKFold con 5 particiones. Para evitar fuga de información entre ventanas solapadas, todas las ventanas pertenecientes a una misma contracción muscular fueron agrupadas dentro del mismo grupo, garantizando que ninguna repetición apareciera simultáneamente en entrenamiento y test.

3. Resultados y Benchmarking

Con el objetivo de evaluar la coherencia fisiológica de la señal EMG adquirida, se realizó un proceso de benchmarking con la base de datos NinaPro. Para ello, tanto la señal experimental como la señal de referencia fueron sometidas a la misma cadena de procesamiento digital, incluyendo filtrado, rectificación y obtención de la envolvente.

La similitud morfológica entre ambas señales se evaluó mediante el coeficiente de correlación de Pearson. Este coeficiente toma valores en el rango [-1, 1], siendo valores cercanos a 1 indicativos de una alta similitud entre señales. Además, se calculó el p-valor asociado al coeficiente de correlación, que permite evaluar la significación estadística de la relación observada.

Adicionalmente, se utilizó el error cuadrático medio (RMSE) como medida complementaria de la diferencia entre ambas señales.

Los resultados obtenidos muestran una elevada similitud morfológica entre la señal experimental y la señal de referencia de NinaPro, especialmente tras el proceso de alineamiento y promediado (folding). Las comparaciones morfológicas entre la señal experimental y la señal de referencia de NinaPro para los distintos gestos se muestran en las Figuras 5, 6 y 7.




Figura 5. Mi pulgar vs NinaPro




Figura 6. Mi puño vs NinaPro




Figura 7. Mi palma vs NinaPro

Los valores cuantitativos de similitud morfológica obtenidos para cada gesto se resumen en la Tabla 1.

Gesto	Pearson (r)	p-valor	RMSE
Pulgar	0.85255	0.0	0.16743
Puño	0.81896	0.0	0.15163
Palma	0.65757	0.0	0.22506

Tabla 1. Valores cuantitativos de similitud

En particular, se obtuvieron valores elevados del coeficiente de correlación de Pearson, acompañados de p-valoros significativamente bajos ($p < 0.05$), lo que indica que la similitud observada no es debida al azar, sino que refleja una relación estadísticamente significativa entre ambas señales. Los valores de RMSE obtenidos fueron reducidos, reforzando la concordancia entre las señales comparadas.

En cuanto al rendimiento del sistema de clasificación, se empleó un modelo Random Forest utilizando como variables de entrada las características temporales extraídas (RMS, MAV, ZC, VAR y WL). La evaluación se realizó mediante validación cruzada basada en GroupKFold con 5 particiones.

El análisis por clase mostró precisiones de 0.99 para el estado neutral, 0.92 para el gesto de palma, 0.90 para el gesto de pulgar y 0.85 para el gesto de puño. La precisión promedio por clase (macro-precisión) obtenida fue de 0.916, proporcionando una estimación más equilibrada del rendimiento del modelo entre los distintos gestos considerados.

A pesar de que el coeficiente de correlación de Pearson obtenido para el gesto de la palma es inferior al de otros gestos, el modelo de clasificación mantiene un rendimiento elevado. Este resultado puede explicarse por la diferencia entre la similitud morfológica global y la capacidad discriminativa de las características utilizadas. Mientras

que el coeficiente de Pearson evalúa la similitud en la forma completa de la señal, el modelo Random Forest se basa en características estadísticas como RMS, MAV, VAR y WL, capaces de capturar propiedades energéticas y temporales relevantes de la señal EMG.

Aunque el estado neutral presenta un mayor número de muestras y por ello también una precisión especialmente elevada, la evaluación mediante macro-precisión permitió obtener una estimación más equilibrada y sincera del rendimiento del clasificador entre los distintos gestos considerados.

La matriz de confusión resultante se muestra en la Figura 8, donde se observa un elevado grado de acierto en la clasificación de los distintos gestos. No obstante, se detectan ciertas confusiones principalmente entre los gestos de puño y pulgar, así como entre puño y palma, lo que sugiere la existencia de patrones de activación muscular parcialmente similares entre dichas clases.




Figura 8. Matriz de confusión

Este comportamiento puede explicarse en parte por el nivel de ruido presente en la señal, reflejado en el valor de SNR obtenido (alrededor de 10 dB), que limita la separabilidad entre clases.

En conjunto, los resultados indican que, a pesar de la simplicidad del sistema monocanal, es posible obtener un rendimiento competitivo tanto en términos de similitud morfológica como de clasificación, lo que refuerza su viabilidad para aplicaciones de interacción humano-máquina.

4. Discusión

Los resultados obtenidos ponen de manifiesto la relación existente entre la calidad de la señal EMG adquirida y el rendimiento del sistema de clasificación. En particular, el valor de SNR obtenido (alrededor de 10 dB) indica la presencia de un nivel de ruido significativo en la señal, lo que afecta directamente a la separabilidad entre clases. Este efecto se refleja en la matriz de confusión, donde se observan errores de clasificación entre los gestos de puño y pulgar, así como entre los gestos de puño y palma. Estas confusiones pueden explicarse por la similitud existente entre determinados patrones de activación muscular, lo que, combinado con el nivel de ruido presente en la señal, dificulta su diferenciación por parte del clasificador.

El gesto de la palma presenta un valor de correlación inferior al de otros gestos, lo que puede explicarse por su mayor complejidad muscular. A diferencia de gestos como el puño o el pulgar, que implican activaciones más localizadas, la apertura de la mano involucra un conjunto más amplio de músculos, dando lugar a un patrón de activación más distribuido. El uso de un sistema monocanal limita la capacidad de capturar toda la información espacial de la activación muscular, lo que se traduce en una menor similitud morfológica con la señal de referencia de NinaPro. Esta limitación es inherente al sistema de adquisición y pone de manifiesto la importancia del número de canales en la caracterización de gestos complejos.

5. Conclusiones y Trabajo futuro

El sistema desarrollado demuestra la viabilidad técnica de arquitecturas electromiográficas (sEMG) monocanal de bajo coste para la discriminación de patrones motores básicos, alcanzando una precisión de clasificación elevada en tareas de reconocimiento gestual simples. No obstante, el análisis experimental pone de manifiesto varias limitaciones críticas relacionadas con la robustez, la seguridad y el determinismo temporal del sistema, las cuales condicionan su aplicación en entornos reales.

En primer lugar, la relación señal-ruido (SNR) obtenida de alrededor de 10 dB introduce una incertidumbre estadística que se manifiesta en la superposición de hiperplanos de decisión del clasificador; específicamente, la matriz de confusión evidencia una tasa de error crítica entre los gestos de pulgar y puño, así como entre los gestos de puño y palma, lo que comprometería la estabilidad del actuador ante falsas activaciones espurias.

Por otro lado, el determinismo temporal del sistema se ve penalizado por la cadena de preprocesamiento y segmentación. La concatenación de ventanas deslizantes de 200 ms, el suavizado por media móvil de 50 ms y el filtro de consistencia temporal imponen una latencia acumulada intrínseca. Este retardo total de aproximadamente 325 ms restringe la capacidad de respuesta en tiempo real del lazo de control cerrado.

Por consiguiente, mientras que el control mioeléctrico monocanal es desestimable para aplicaciones robóticas de alta precisión o manipulación dinámica, se valida su idoneidad exclusivamente para interfaces de comandos discretos, esto puede ser, el control básico de menús o la activación y desactivación de dispositivos simples (encender y apagar luces, control de ventilación...).

Finalmente, como líneas futuras de trabajo, resultaría de interés ampliar el número de gestos reconocidos, validar el sistema sobre un conjunto más amplio y heterogéneo de usuarios e incorporar arquitecturas multicanal que permitan mejorar la separabilidad entre clases y aumentar la robustez frente al ruido y las variaciones fisiológicas.